Méthode des plus proches voisins

Formation animée par ELGTARI Saif Eddine
Ingénieur en Sciences des Données & IA

I. Introduction
II. Objectifs
III. Méthode du plus proche voisin
IV. Méthode des plus proches voisins
V. Distances
VI. Exemple

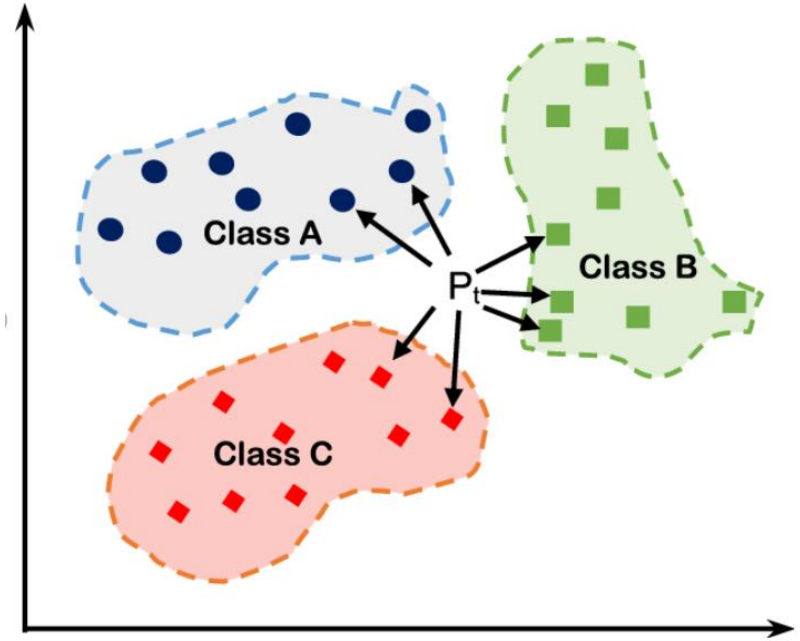

I. Introduction

Ce chapitre présente un algorithme de prédiction non paramétrique conceptuellement très simple, qui permet de construire des frontières de décision complexes sans faire aucune hypothèse sur la distribution des données.
Cet algorithme, dit des plus proches voisins, se base sur le principe de « qui se ressemble s'assemble », et utilise les étiquettes des exemples les plus proches pour prendre une décision.

La puissance de cet algorithme venant du choix de la fonction utilisée pour définir cette proximité entre observations.

Ce chapitre sera aussi l'occasion de définir des distances et similarités pour différentes représentations des données.

Nous montrerons comment les plus proches voisins peuvent être utilisés en pratique dans le cadre du filtrage collaboratif.

II. Objectifs

- Implémenter l'algorithme des k plus proches voisins.
- Calculer distances et similarités pour différents types de représentations des données.
- Définir la frontière de décision de l'algorithme du plus proche voisin.
- Expliquer pourquoi l'algorithme des k plus proches voisins est susceptible de ne pas marcher en haute dimension.

III. Méthode du plus proche voisin

Définition :

Etant donné un jeu $\mathcal{D} = \{(x_i, y_i)\}_{i=1,\dots,n}$ de n observations étiquetées, et une distance d sur $\mathcal{X}$, on appelle **algorithme du plus proche voisin** l'algorithme consistant à étiqueter une nouvelle observation x par l'étiquette du point du jeu d'entrainement qui en est la plus proche.

Cet algorithme s'applique aussi bien à un problème de classification qu'à un problème de régression.

III. Méthode du plus proche voisin

Diagramme de Voronoi :

L'algorithme du plus proche voisin crée une partition de $\mathcal{X}$ en n parties; la $i^{ème}$ de ces parties est l'ensembles des points de $\mathcal{X}$ dont le plus proche voisin dans $\mathcal{D}$ est x_i :

$$\mathcal{X} = \bigcup_{i=1}^{n} \{x \in \mathcal{X} \ : \ d(x, x_i) \leq d(x, x_l) \ \ \forall x_l \in \mathcal{D}\}$$

Cette partition est ce que l'on appelle une diagramme de Voronoi.

Définition : soient un espace métrique $\mathcal{X}$ muni de la distance $d : \mathcal{X} * \mathcal{X} \ \rightarrow \mathbb{R}$, et un ensemble fini δ d'éléments de $\mathcal{X}$.
Etant donné un élément $u \in \delta$ (appelé germe), on appelle cellule de Voronoi l'ensemble défini par :

$$Vor(u) = \{x \in \mathcal{X} \ : \forall \, v \in \ \delta, \qquad d(x, u) \ \leq d(x, v)\}$$

Une cellule de Voronoi est un ensemble convexe, et l'union de toutes les cellules de Voronoi forme une partition de $\mathcal{X}$ appelée diagramme de Voronoi :

$$\mathcal{X} = \bigcup_{u \in \delta} vor(u)$$

III. Méthode du plus proche voisin

Une autre façon de présenter l'algorithme du plus proche voisin est de le voir comme une partition de $\mathcal{X}$ en autant de parties qu'il existe d'étiquettes distinctes dans le jeu d'entraînement.
La partie correspondant à l'étiquette y est l'union des cellules de Voronoi correspondant à une observation de $\mathcal{D}$ étiquetée par y :

$$\mathcal{X} = \bigcup_{y} \{x \in \mathcal{X} \ : \ y_{argmin\,,i=1\ldots n} \ d(x, x_i) = y\}$$

Ainsi cet algorithme très simple permet de construire une frontière de décision beaucoup plus complexe qu'un algorithme paramétrique linéaire.

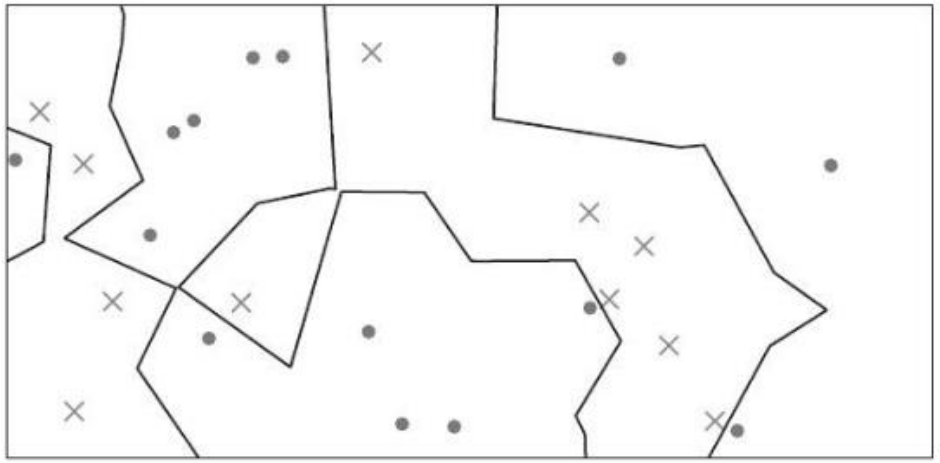

IV. Méthode des plus proches voisins

La méthode du plus proche voisin a le défaut d'être très sensible au bruit : si une observation est mal étiquetée, ou mal positionnée, tous les points dans sa cellule (sa classe) seront mal étiquetés.

Pour rendre cette méthode plus robuste, on se propose de combiner les « opinions » de plusieurs voisins de l'observation que l'on cherche à étiqueter.

1. Méthode des k plus proches voisins

Définition :

Etant donné un jeu $\mathcal{D} = \{(x_i, y_i)\}_{i=1,\dots,n}$ de n observations étiquetées, une distance d sur $\mathcal{X}$, et un hyperparamètre $k \in \mathbb{N}^*$, on appelle algorithme des k plus proches voisins (KNN : k nearest neighbors), l'algorithme consistant à étiqueter une nouvelle observation x en fonction des étiquettes des k points du jeu d'entrainement dont elle est la plus proche.

En notant $\mathcal{N}_k(x)$ l'ensemble des k plus proches voisins de x dans $\mathcal{D}$:

- Pour un problème de classification, on applique le vote de la majorité, et x prend l'étiquette majoritaire parmi celles de ses k plus proches voisins :

$$\boldsymbol{f(x) = \underset{c}{\operatorname{argmax}} \sum_{i:x_i \in \mathcal{N}_k(x)} \delta(y_i, c)}$$

- Pour un problème de régression, x prend comme étiquette la moyenne des étiquettes de ses k plus proches voisins :

$$\boldsymbol{f(x) = \frac{1}{k} \sum_{i:x_i \in \mathcal{N}_k(x)} y_i}$$

1. Méthode des k plus proches voisins

L'algorithme des k plus proches voisins est un exemple d'apprentissage non paramétrique. La fonction de décision s'exprime en fonction des données observées et non pas comme une formule analytique fonction des variables.

On peut rapprocher son fonctionnement de celui d'un raisonnement par cas, qui consiste à agir en se remémorant les choix déjà effectuées dans des situations semblables précédemment rencontrées, qui se retrouve par exemple lorsqu'un médecin traite un patient en se remémorant comment d'autres patients avec des symptômes similaires ont guéri.

La frontière de décision de l'algorithme des k plus proches voisins est linéaire par morceaux ; quand k augmente, elle devient plus « simple », car le vote de la majorité permet de lisser les aspérités créées par les exemples individuels

3. Nombre de plus proches voisins

Nous proposons d'utiliser $k > 1$ pour rendre l'algorithme des k plus proches voisins plus robustes au bruit.

Cependant, à l'inverse, si $k = n$, l'algorithme prédira, dans le cas d'un problème de classification, la classe majoritaire dans $\mathcal{D}$, et dans le cas d'un problème de régression, la moyenne des étiquettes de $\mathcal{D}$, ce qui parait tout aussi peu satisfaisant.

Il faudra donc choisir une valeur de k intermédiaire, ce que l'on fera généralement en utilisant une validation croisée.

Ecriture algorithmique

Début Algorithme

Données en entrée :

- Un ensemble de données D
- Une fonction de définition distance d
- Un nombre entier K

Pour une nouvelle observation X dont on veut prédire sa variable de sortie y Faire :

1. Calculer toutes les distances de cette observation X avec les autres observations du jeu de données D

2. retenir les K observations du jeu de données D les proches de X en utilisation le fonction de calcul de distance d

3. prendre les valeurs de y des K observations retenues :

   Si on effectue une régression, calculer la moyenne (ou la médiane) de y retenues

   Si on effectue une classification , calculer le mode de y retenues

4. Retourner la valeur calculée dans l'étape 3 comme étant la valeur qui a été prédite par K-NN pour l'observation X.

Fin Algorithme

V. Distances

La distance euclidienne : distance qui calcule la racine carrée de la somme des différences carrées entre les coordonnées de deux points :

$$D_e(x,y) = \sqrt{\sum_{j=1}^{n}(x_j - y_j)^2}$$

Distance Manhattan : la distance de Manhattan: calcule la somme des valeurs absolues des différences entre les coordonnées de deux points :

$$D_m(x,y) = \sum_{i=1}^{k} \mid x_i - y_i \mid$$

VI. Exemple : client loyal ou non ?

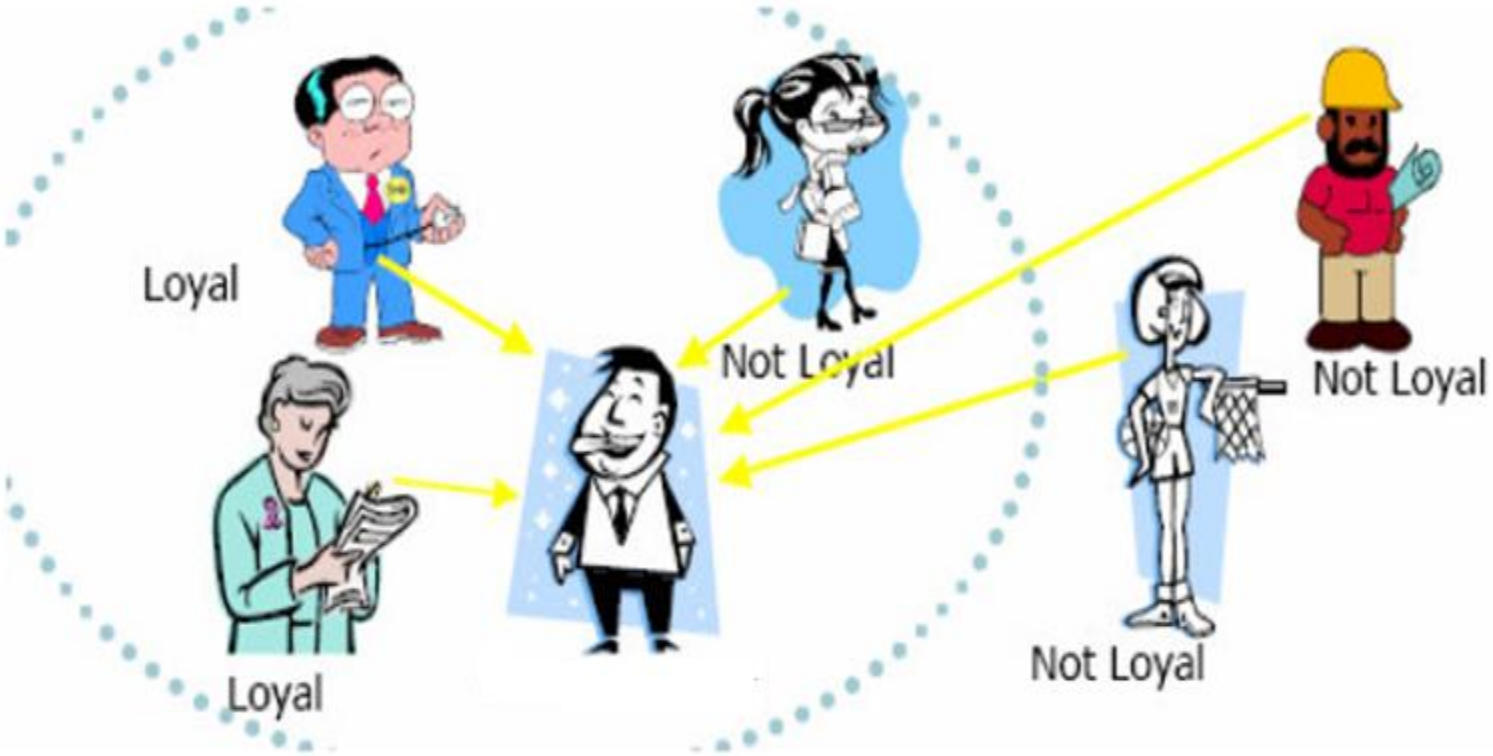

Customer	Age	Income	No. credit cards	Loyal
John	35	35K	3	No
Rachel	22	50K	2	Yes
Hannah	63	200K	1	No
Tom	59	170K	1	No
Nellie	25	40K	4	Yes
David	37	50K	2	?

En utilisant la **distance euclidienne** et pour **k=3**, déterminer est-ce que David va être loyal ou non ?

K=3

Customer	Age	Income	No. credit cards	Loyal	Distance from David
John	35	35K	3	No	sqrt $[(35-37)^2+(35-50)^2+(3-2)^2]=\mathbf{15.16}$
Rachel	22	50K	2	Yes	sqrt $[(22-37)^2+(50-50)^2+(2-2)^2]=\mathbf{15}$
Hannah	63	200K	1	No	sqrt $[(63-37)^2+(200-50)^2+(1-2)^2]=\mathbf{152.23}$
Tom	59	170K	1	No	sqrt $[(59-37)^2+(170-50)^2+(1-2)^2]=\mathbf{122}$
Nellie	25	40K	4	Yes	sqrt $[(25-37)^2+(40-50)^2+(4-2)^2]=\mathbf{15.74}$
David	37	50K	2	**Yes**	

Classe majoritaire

Prédiction : David est un client loyal